

Bộ dữ liệu bệnh tiểu đường của người phụ nữ da đỏ Pima

Vũ Ngọc Tùng, Tạ Quang Thắng, Phạm Hồng Thái,
Phan Thanh Tùng

Saigon University, Vietnam.

Liên hệ tác giả: E-mail(s): tungvu11305@gmail.com;
taquangthang2005@gmail.com; hongthaipham62@gmail.com;
phanthanhtung071105@gmail.com;

Các tác giả đóng góp công bằng trong bài báo này.

Tóm tắt

Bệnh tiểu đường là một trong những bệnh không lây nhiễm phổ biến nhất trên toàn cầu, một trong những thách thức lớn đối với y tế công cộng. Việc phát hiện sớm và chẩn đoán chính xác bệnh tiểu đường đóng vai trò quan trọng trong việc ngăn ngừa biến chứng nghiêm trọng và giảm chi phí điều trị. Tuy nhiên, phần lớn các trường hợp vẫn chưa được chẩn đoán do triệu chứng khởi phát không rõ ràng và tình trạng thiếu nhân lực y tế ở các khu vực vùng sâu vùng xa. Trong bối cảnh đó, việc kết hợp giữa học máy (Machine Learning) và Internet y tế (IoMT) mở ra hướng tiếp cận mới, giúp xây dựng hệ thống chẩn đoán tự động và thông minh. Nghiên cứu này hướng đến việc phát triển hệ thống chẩn đoán điện tử (e-diagnosis) dựa trên IoMT để phát hiện và phân loại bệnh tiểu đường bằng các thuật toán học máy như Logistic Regression, Random Forest và XGBoost. Dữ liệu được sử dụng là bộ dữ liệu Pima Indians Diabetes – bộ dữ liệu bệnh tiểu đường của người phụ nữ da đỏ Pima, một tập dữ liệu chuẩn trong nghiên cứu học máy, bao gồm thông tin sức khỏe của phụ nữ người da đỏ Pima từ 21 tuổi trở lên – nhóm dân cư có tỷ lệ mắc tiểu đường cao. Bằng cách phân tích các chỉ số y học quan trọng như mức đường huyết, huyết áp và chỉ số BMI, hệ thống dự đoán khả năng mắc bệnh tiểu đường và hỗ trợ bác sĩ trong việc ra quyết định kịp thời. Hiệu suất mô hình được đánh giá qua các chỉ số như độ chính xác, độ nhạy, độ đặc hiệu, F-measure và AUROC. Kết quả cho thấy, các mô hình học máy có tiềm năng lớn trong việc nâng cao hiệu quả chẩn đoán sớm và hỗ trợ y tế, đặc biệt tại các khu vực còn hạn chế nguồn lực.

Từ khoá: Pima Indians, Pima Indians Diabetes, dữ liệu mẫu Pima Indians Diabetes, dự đoán bệnh tiểu đường, phân tích dữ liệu y tế, Internet of Medical Things (IoMT)

1. Giới thiệu

Bệnh tiểu đường (Diabetes mellitus), hay đơn giản là tiểu đường, là một trong những bệnh không lây nhiễm hàng đầu trên toàn cầu, với số ca mắc gần như tăng gấp đôi kể từ năm 1980. Đây là một bệnh mạn tính hình thành khi tuyến tụy không thể sản xuất đủ insulin, hoặc cơ thể không sử dụng hiệu quả lượng insulin được tạo ra. Hiện chưa có phương pháp chữa khỏi hoàn toàn căn bệnh này.

Bệnh tiểu đường được cho là kết quả của sự kết hợp giữa yếu tố di truyền và yếu tố môi trường. Một số yếu tố nguy cơ liên quan đến bệnh bao gồm: chủng tộc, tiền sử gia đình, tuổi tác, thừa cân, chế độ ăn uống không lành mạnh, ít vận động thể chất và hút thuốc lá. Ngoài ra, việc thiếu phát hiện sớm bệnh tiểu đường còn góp phần dẫn đến sự phát triển của các bệnh mạn tính khác, chẳng hạn như bệnh thận. Hơn nữa, các bệnh không lây nhiễm sẵn có cũng làm tăng nguy cơ cho bệnh nhân, khiến họ dễ mắc các bệnh truyền nhiễm như COVID-19. Việc dự đoán nguy cơ mắc bệnh mạn tính như tiểu đường ở từng cá nhân là một nhiệm vụ quan trọng. Chẩn đoán sớm giúp giảm chi phí y tế và hạn chế biến chứng sức khỏe nghiêm trọng. Trong các tình huống khẩn cấp, khi bệnh nhân bất tỉnh hoặc không thể giao tiếp, việc rút ra kết luận chính xác từ các chỉ số y học có thể đo ngay lập tức là rất cần thiết để giúp bác sĩ ra quyết định điều trị hiệu quả trong các trường hợp có nguy cơ cao.

Phần lớn các trường hợp bệnh không lây nhiễm (NCD) hiện nay vẫn chưa được chẩn đoán, do bệnh nhân thường ít có triệu chứng rõ ràng trong giai đoạn đầu. Điều này gây khó khăn lớn cho việc phát hiện và chẩn đoán sớm. Việc điều trị bệnh nhân ngay từ giai đoạn đầu có thể giúp họ tránh được các chi phí điều trị tốn kém hơn về sau khi bệnh tiến triển nặng. Tuy nhiên, vấn đề này càng trở nên nghiêm trọng hơn do thiếu đội ngũ y tế ở các khu vực vùng sâu, vùng xa. Trong những trường hợp như vậy, sự kết hợp giữa Internet y tế (IoMT) và các mô hình học máy (machine learning) có thể được sử dụng để hỗ trợ các chuyên gia y tế trong việc phát hiện và chẩn đoán sớm các bệnh không lây nhiễm, bằng cách cung cấp các công cụ dự đoán hỗ trợ ra quyết định chính xác và kịp thời hơn. Cũng cần lưu ý rằng các giải pháp học máy vẫn thường bị nghi ngờ do hiện tượng gọi là “hộp đen” (black-box) — tức là không thể giải thích được quá trình ra quyết định bên trong của mô hình. Sự thiếu minh bạch và khả năng giải thích (explainability) này khiến người dùng nghi ngờ và chậm chấp nhận các công nghệ học máy trong lĩnh vực y tế. Do đó, khả năng giải thích rõ ràng cả lý do và quá trình dự đoán của mô hình là yếu tố cốt lõi để xây dựng niềm tin, đặc biệt trong y học — nơi mà sai sót có thể gây hậu quả nghiêm trọng.

Bài báo này hướng đến việc phát triển một hệ thống chẩn đoán điện tử (e-diagnosis) nhằm phát hiện và phân loại bệnh tiểu đường như một ứng dụng của IoMT. Thông qua việc áp dụng các thuật toán học máy gồm Logistic Regression, Random Forest và XGBoost, hệ thống có thể dự đoán nguy cơ mắc tiểu đường của một cá nhân dựa trên các yếu tố nguy cơ, cung cấp cho bác sĩ kết quả chẩn đoán ban đầu, đồng thời gửi lại khuyến nghị về chế độ ăn uống, luyện tập và kiểm tra đường huyết cho bệnh nhân. Các mô hình phân loại này được đánh giá dựa trên nhiều chỉ số hiệu suất gồm: độ chính xác (Accuracy), độ chính xác theo lớp (Precision), độ nhạy (Sensitivity), F-measure và diện tích dưới đường cong ROC (AUROC) để xác định mô hình hoạt động tốt nhất. Từ đó, các đặc trưng quan trọng giúp dự đoán mức độ nghiêm trọng của bệnh tiểu đường được rút trích từ mô hình có hiệu năng cao nhất. Trong nghiên cứu này, bộ dữ liệu Pima Indians Diabetes được sử dụng. Người Pima là một nhóm người bản địa ở Bắc Mỹ, sinh sống tại Mexico và bang Arizona (Hoa Kỳ). Nhóm này có tỷ lệ mắc bệnh tiểu đường cao, do đó, việc nghiên cứu họ được xem là đại diện và có ý nghĩa

đối với sức khỏe toàn cầu. Bộ dữ liệu này bao gồm phụ nữ người Pima từ 21 tuổi trở lên, và là một tập dữ liệu chuẩn phổ biến trong nghiên cứu học máy. Đồng thời, nhóm dân cư này cũng đại diện cho các cộng đồng thiểu số và bản địa chưa được nghiên cứu đầy đủ. Các đặc trưng của bộ dữ liệu bao gồm những chỉ số y học có thể đo lường nhanh, không đòi hỏi kiểm tra chuyên sâu, giúp hữu ích trong các tình huống khẩn cấp và chăm sóc sức khỏe cá nhân, vốn đang ngày càng phổ biến.

2. Tập dữ liệu

2.1 Tổng quan tập dữ liệu


Bộ dữ liệu Pima Indians Diabetes là một trong những tập dữ liệu kinh điển và phổ biến nhất trong lĩnh vực học máy (machine learning) và y học dự đoán (medical prediction). Bộ dữ liệu này được công bố bởi Viện Quốc gia về Bệnh tiểu đường, Tiêu hóa và Thận (National Institute of Diabetes and Digestive and Kidney Diseases – NIDDK).

Mục tiêu của bộ dữ liệu là dự đoán khả năng mắc bệnh tiểu đường ở phụ nữ người da đỏ Pima (một nhóm dân tộc bản địa ở Bắc Mỹ), từ 21 tuổi trở lên, dựa trên các chỉ số y học cơ bản có thể thu thập được trong các lần khám sức khỏe thông thường.

Bộ dữ liệu bao gồm 768 mẫu dữ liệu, trong đó:

- 268 mẫu ($\approx 34,9\%$) thuộc nhóm mắc bệnh tiểu đường (Positive),
- 500 mẫu ($\approx 65,1\%$) thuộc nhóm không mắc bệnh (Negative).

Mỗi bản ghi (mẫu) bao gồm 8 thuộc tính đầu vào (features) và 1 thuộc tính đầu ra (class label) thể hiện tình trạng bệnh tiểu đường.



tiêu chí đánh giá mô hình

Sau khi khảo sát tổng quan, dữ liệu Pima Indian thể hiện tính cân bằng tương đối về kích thước nhưng mất cân đối nhẹ giữa hai nhãn đầu ra (khoảng 35% bệnh nhân mắc bệnh và 65% không mắc bệnh). Một số thuộc tính chứa giá trị bằng 0 ở các cột như BloodPressure, BMI,

SkinThickness hoặc Insulin, điều này không hợp lý về mặt y học (ví dụ: huyết áp hoặc độ dày da không thể bằng 0). Vì vậy, cần thực hiện tiền xử lý dữ liệu (data preprocessing), bao gồm xử lý giá trị thiếu, chuẩn hóa dữ liệu, và phát hiện ngoại lệ (outliers) để đảm bảo độ chính xác và độ tin cậy của mô hình sau này.

2.2 Cơ sở dữ liệu

Tập dữ liệu gồm 8 thuộc tính đầu vào và 1 thuộc tính đầu ra, cụ thể các thuộc tính được thể hiện như bảng sau:

STT	Thuộc tính	Mô tả	Đơn vị / Giá trị
1	Pregnancies	Số lần mang thai của bệnh nhân	Số nguyên
2	Glucose	Nồng độ glucose trong huyết tương sau 2 giờ trong bài kiểm tra dung nạp glucose	mg/dL
3	BloodPressure	Huyết áp tâm trương (Diastolic Blood Pressure)	mm Hg
4	SkinThickness	Độ dày của nếp gấp da (Triceps skin fold thickness)	mm
5	Insulin	Nồng độ insulin huyết thanh 2 giờ	μ U/mL
6	BMI	Chỉ số khối cơ thể (Body Mass Index) = cân nặng (kg) / (chiều cao (m)) ²	kg/m ²
7	DiabetesPedigreeFunction	Chỉ số di truyền tiểu đường (đánh giá ảnh hưởng của di truyền trong gia đình)	-
8	Age	Tuổi của bệnh nhân	Năm
9	Outcome	Nhãn phân loại (0: Không tiểu đường, 1: Có tiểu đường)	0 hoặc 1

Bảng 1: Các thuộc tính của mô hình

Nguồn dữ liệu được thu thập trong khuôn khổ nghiên cứu của National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK). Tập dữ liệu không chứa thông tin định danh cá nhân, đảm bảo tính ẩn danh và bảo mật dữ liệu y tế. Tập dữ liệu tập trung vào nhóm phụ nữ người da đỏ Pima sống tại bang Arizona (Hoa Kỳ), đây là cộng đồng được ghi nhận có tỷ lệ mắc bệnh tiểu đường type II cao nhất thế giới, do các yếu tố di truyền, chế độ ăn uống và lối sống hiện đại hóa nhanh.

Bộ dữ liệu Pima Indians Diabetes được lưu trữ và phân phối công khai thông qua:

- Kho dữ liệu UCI Machine Learning Repository,
- Thư viện Scikit-learn (Python) (load_diabetes() hoặc fetch_openml('diabetes')),
- Và nhiều nền tảng học máy khác như Kaggle.

Dữ liệu được định dạng ở dạng CSV (Comma-Separated Values), dễ dàng sử dụng cho các mô hình học máy. Trước khi huấn luyện, dữ liệu thường được:

- Kiểm tra và xử lý giá trị thiếu (nhiều thuộc tính như Glucose, Insulin, BMI có thể chứa giá trị 0 – được xem là “missing data”),
- Chuẩn hóa (standardization hoặc normalization),
- Chia thành tập huấn luyện (training set) và tập kiểm thử (test set), thông thường theo tỷ lệ 70:30 hoặc 80:20.

Tập dữ liệu này đóng vai trò như chuẩn đánh giá cho nhiều nghiên cứu so sánh thuật toán học máy trong lĩnh vực phân loại bệnh tiểu đường, bao gồm các phương pháp như SVM, Random Forest, Decision Tree, Logistic Regression, và các mô hình học sâu hiện đại.

3. Mô hình

Sau khi tiền xử lý và đánh giá đặc trưng của tập dữ liệu Pima Indian Diabetes, nghiên cứu này tiến hành huấn luyện và so sánh hiệu suất của ba mô hình học máy phổ biến trong bài toán phân loại nhị phân (binary classification), bao gồm

- Logistic Regression (LR)
- Random Forest (RF)
- Extreme Gradient Boosting (XGBoost)

Ba mô hình trên được lựa chọn vì chúng đại diện cho ba hướng tiếp cận khác nhau trong học máy:

- Hồi quy tuyến tính xác suất (probabilistic linear model) — Logistic Regression.
- Phương pháp tổng hợp mô hình cây quyết định (ensemble of decision trees) — Random Forest.
- Thuật toán tăng cường (boosting) mạnh mẽ và tối ưu hóa hiệu suất cao — XGBoost.

Việc kết hợp ba phương pháp này giúp so sánh mức độ giải thích, độ chính xác, khả năng tổng quát hóa và hiệu quả dự đoán của từng mô hình trên cùng một bộ dữ liệu y sinh học.

Mô hình Logistic Regression là một mô hình tuyến tính được sử dụng rộng rãi trong phân loại nhị phân, dựa trên xác suất dự đoán nhãn đầu ra $y \in \{0, 1\}$

$$P(y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}$$

Trong đó:

X_i : Các đặc trưng đầu vào (Glucose, BMI, Age, ...)

β_i : Trọng số (weights) được mô hình học từ dữ liệu huấn luyện

Mục tiêu của LR là tối đa hóa hàm hợp lý (likelihood function) để tìm bộ tham số tốt nhất dự đoán xác suất mắc bệnh tiểu đường.

Mô hình LR có ưu điểm là dễ diễn giải, cho phép đánh giá mức độ ảnh hưởng của từng biến độc lập đến khả năng mắc bệnh. Tuy nhiên, do tính tuyến tính, LR có thể không mô hình hóa được các quan hệ phi tuyến phức tạp trong dữ liệu.

Random Forest là một mô hình ensemble learning dựa trên nhiều cây quyết định (Decision Trees) được huấn luyện độc lập trên các mẫu dữ liệu và đặc trưng ngẫu nhiên. Kết quả cuối cùng được xác định bằng trung bình hoặc biểu quyết đa số (majority voting) từ các cây con.

Cơ chế hoạt động chính gồm:

- Bootstrap Aggregation (Bagging): Tạo nhiều tập con ngẫu nhiên từ dữ liệu gốc để huấn luyện từng cây.
- Random Feature Selection: Mỗi cây chỉ chọn một tập nhỏ ngẫu nhiên các đặc trưng tại mỗi nút phân chia, giúp giảm hiện tượng overfitting.

Random Forest có khả năng xử lý dữ liệu nhiễu, mất cân đối và phi tuyến tốt, đồng thời ước lượng được tầm quan trọng của từng biến (feature importance) — rất hữu ích trong việc xác định các yếu tố y học quan trọng ảnh hưởng đến bệnh tiểu đường.

Nhược điểm chính là tính khó diễn giải hơn so với Logistic Regression và thời gian huấn luyện lâu hơn khi dữ liệu lớn.

Mô hình Extreme Gradient Boosting (XGBoost) là một biến thể nâng cao của thuật toán Gradient Boosting, được thiết kế để tối ưu hóa tốc độ và độ chính xác của mô hình dự đoán.

Cơ chế của XGBoost là xây dựng các cây quyết định tuần tự, trong đó mỗi cây mới được huấn luyện để sửa lỗi mà mô hình trước đó mắc phải. Thuật toán này sử dụng gradient descent để giảm thiểu hàm mất mát (loss function), đồng thời áp dụng regularization (L1, L2) giúp kiểm soát overfitting.

Ưu điểm nổi bật của XGBoost:

- Xử lý tốt dữ liệu phi tuyến, nhiễu hoặc không cân đối.
- Hỗ trợ song song hóa (parallel processing) giúp huấn luyện nhanh hơn.
- Cho phép đánh giá tầm quan trọng đặc trưng (feature importance) với độ tin cậy cao.

Nhờ vậy, XGBoost thường đạt độ chính xác cao hơn so với các mô hình truyền thống và được xem là một trong những mô hình mạnh mẽ nhất trong các bài toán phân loại y học hiện nay.

4. Triển khai thí nghiệm

Kết quả tổng quát của từng mô hình

Mô hình	CV Accuracy	CV ROC AUC
XGBoost	0.7468	0.8204
LogisticRegression	0.76	0.829
Random Forest	0.7403	0.8076

Bảng 2: Kết quả các mô hình

Dựa vào kết quả độ chính xác từ *Bảng 2* dễ thấy rằng đối với CV Accuracy thì Logistic Regression đạt hiệu suất cao nhất (76.0%), theo sau là XGBoost (74.68%) và Random Forest (74.03%). Sự chênh lệch nhỏ (khoảng 2%) cho thấy tất cả mô hình đều có độ chính xác trung bình khá tốt trên dataset này, vượt qua baseline ngẫu nhiên (~65% do lớp không cân bằng).

Đối với CV ROC AUC: Logistic Regression tiếp tục dẫn đầu (~ 82,9%), chứng tỏ khả năng phân biệt tốt nhất giữa lớp tiểu đường và không (AUC > 80 % là mức chấp nhận được cho bài toán y tế). XGBoost (82,04 %) và Random Forest (80,76 %) cũng mạnh, nhưng thấp hơn một chút, có thể do tree-based models nhạy cảm hơn với outliers trong dataset (như giá trị Glucose = 0). Xu hướng chung cho thấy rằng Logistic Regression vượt trội ở cả hai metric, phù hợp với dataset có đặc trưng tương đối tuyến tính (như Glucose và BMI có mối quan hệ tuyến tính với nhãn). Các mô hình ensemble (XGBoost và Random Forest) có hiệu suất tương đương nhau, nhưng XGBoost nhỉnh hơn nhẹ nhờ tối ưu hóa gradient boosting.

Tổng thể, Logistic Regression là mô hình tốt nhất cho dataset này với hiệu suất vượt trội (Accuracy 76%, AUC 0.829), phù hợp cho ứng dụng y tế cần giải thích rõ ràng. XGBoost và Random Forest là lựa chọn thay thế mạnh mẽ cho các tình huống phức tạp hơn, với tiềm năng cải thiện qua tuning. Trong báo cáo, nhấn mạnh rằng tất cả mô hình đều đạt >74% Accuracy – mức chấp nhận được cho dự đoán tiểu đường – nhưng nên kết hợp với đánh giá lâm sàng. Để minh họa, có thể thêm confusion matrix hoặc ROC curve cho từng mô hình.

5. Kết luận

Mặc dù quá trình xử lý và mô hình hóa dữ liệu Pima Indian Diabetes gặp nhiều thách thức — đặc biệt ở các giai đoạn làm sạch dữ liệu, chuẩn hóa giá trị thiếu, và kiểm soát hiện tượng mất cân bằng lớp (class imbalance) — nghiên cứu đã đạt được các kết quả tích cực, thể hiện tính khả thi của việc ứng dụng học máy trong dự đoán nguy cơ mắc bệnh tiểu đường.

Ba mô hình được triển khai gồm Logistic Regression, Random Forest, và XGBoost đại diện cho ba hướng tiếp cận khác nhau: tuyến tính, rừng ngẫu nhiên và tăng cường gradient. Qua quá trình huấn luyện, hiệu chỉnh tham số (hyperparameter tuning) và đánh giá bằng các thước đo Accuracy, Precision, Recall, F1-score, và ROC-AUC, kết quả cho thấy:

- Random Forest đạt hiệu suất ổn định và khả năng tổng quát hóa tốt nhất, cân bằng giữa độ chính xác và khả năng giải thích.
- XGBoost thể hiện độ chính xác và ROC-AUC cao nhất, cho thấy khả năng học sâu các quan hệ phi tuyến giữa các đặc trưng y học, tuy nhiên có xu hướng overfitting nhẹ trên tập huấn luyện.
- Logistic Regression dù đơn giản hơn, nhưng vẫn đạt hiệu quả dự đoán đáng tin cậy, đồng thời mang lại khả năng diễn giải cao, giúp xác định rõ những đặc trưng có tác động mạnh nhất đến khả năng mắc bệnh.

Nhìn chung, kết quả thực nghiệm khẳng định rằng chất lượng của dữ liệu và chiến lược xử lý đặc trưng (feature engineering) đóng vai trò then chốt trong việc nâng cao hiệu suất của mô hình, không kém phần quan trọng so với việc lựa chọn thuật toán. Việc chuẩn hóa, loại bỏ ngoại lệ, và cân bằng giữa các lớp dữ liệu đã giúp các mô hình đạt được kết quả ổn định và đáng tin cậy.

Trong tương lai, hướng phát triển của nghiên cứu có thể tập trung vào hai khía cạnh chính:

- (1) Mở rộng tập dữ liệu với các chỉ số lâm sàng mới và thông tin di truyền để cải thiện khả năng dự đoán cá nhân hóa;
- (2) Kết hợp các mô hình tiên tiến hơn, bao gồm học sâu (Deep Learning) hoặc ensemble hybrid (stacking, blending) nhằm tận dụng ưu điểm của từng mô hình, đồng thời tăng tính chính xác và khả năng tự thích ứng với dữ liệu thực tế trong môi trường y tế.

Tổng thể, nghiên cứu này đã chứng minh rằng các mô hình học máy, khi được xử lý dữ liệu và tinh chỉnh hợp lý, hoàn toàn có thể trở thành công cụ hỗ trợ đắc lực trong chẩn đoán sớm bệnh tiểu đường, góp phần giảm tải cho hệ thống y tế và nâng cao hiệu quả điều trị bệnh nhân.

Tài liệu tham khảo

- [1] Chang*, V., Bailey, J., Xu, Q. A., & Sun, Z. (n.d.). *Pima Indians diabetes mellitus classification based on machine learning (ML) algorithms*.

- [2] journalimcms.org. (n.d.). *MACHINE LEARNING BASED PREDICTION AND INSIGHTS OF DIABETES DISEASE: PIMA INDIAN AND FRANKFURT DATASETS*.

- [3] Learning, B. T., & Kaggle. (n.d.). *Pima Indians Diabetes Database*.

- [4] Liu, S. (n.d.). *Diabetes Prediction by KNN, SVM, Random Forest and XGBoost*.

- [5] Victor Chang, . J. (n.d.). *Pima Indians diabetes mellitus classification based on machine learning (ML) algorithms*.