

Dự đoán khả năng sống sót của hành khách sau thảm họa tàu Titanic bằng các thuật toán học máy

Vũ Ngọc Tùng, Tạ Quang Thắng, Phạm Hồng Thái,
Phan Thanh Tùng

Saigon University, Vietnam.

Liên hệ tác giả: E-mail(s): tungvu11305@gmail.com;
taquangthang2005@gmail.com; hongthaipham62@gmail.com;
phanthanhtung071105@gmail.com;

Các tác giả đóng góp công bằng trong bài báo này.

Tóm tắt

Thảm họa chìm tàu Titanic (RMS Titanic) vào năm 1912 được xem là một trong những sự kiện hàng hải chấn động và bi thương nhất trong lịch sử thế giới nói chung và ngành hàng hải nói riêng, cướp đi sinh mạng của hơn 1500 hành khách và thủy thủ đoàn. Từ góc nhìn của khoa học dữ liệu hiện đại, bộ dữ liệu Titanic không chỉ là tư liệu lịch sử mà còn là một bài toán kinh điển để minh họa sức mạnh của các mô hình học máy trong dự đoán kết quả nhị phân. Nghiên cứu này tập trung vào việc xây dựng và so sánh các mô hình học máy nhằm dự đoán khả năng sống sót của hành khách trên chuyến tàu Titanic dựa trên các đặc trưng cá nhân và thông tin hành trình như giới tính, độ tuổi, giá vé, hạng vé và cảng khởi hành của họ. Dữ liệu được lấy từ bộ Titanic – Machine Learning from Disaster trên nền tảng Kaggle. Quy trình nghiên cứu bao gồm các bước cụ thể: tiền xử lý dữ liệu, phân tích mối quan hệ giữa các đặc trưng, trích xuất và mở rộng đặc trưng (feature engineering), sau đó huấn luyện nhiều mô hình khác nhau như Logistic Regression, Random Forest và XGBoost. Các mô hình được đánh giá thông qua các chỉ số Accuracy, F1-Score và ROC AUC để đảm bảo tính khách quan và toàn diện. Kết quả cho thấy mô hình **Random Forest** đạt hiệu năng cao nhất trong việc dự đoán xác suất sống sót của hành khách. Nghiên cứu không chỉ minh chứng tiềm năng ứng dụng của học máy trong việc phân tích dữ liệu lịch sử mà còn khẳng định vai trò quan trọng của kỹ thuật xử lý và chọn lọc đặc trưng trong việc nâng cao hiệu quả dự đoán các mô hình.

Từ khoá: Titanic, Titanic học máy, dữ liệu mẫu Titanic, Phân tích dữ liệu lịch sử, dự đoán sống sót, dự đoán nhị phân

1. Giới Thiệu

Thảm họa chìm tàu RMS Titanic vào năm 1912 không chỉ để lại nỗi đau lớn về nhân mạng mà còn trở thành nguồn tư liệu quý giá cho nhiều nghiên cứu hiện đại. Bộ dữ liệu hành khách trên tàu phản ánh rõ ràng mối quan hệ giữa các yếu tố nhân khẩu học và khả năng sống sót. Chính vì vậy, dữ liệu Titanic đã trở thành một trong những bài toán kinh điển, thường được sử dụng để minh họa cho quá trình xây dựng, huấn luyện và đánh giá các mô hình học máy trong lĩnh vực phân tích dữ liệu.

Trong bối cảnh cuộc cách mạng công nghiệp 4.0, nơi dữ liệu và trí tuệ nhân tạo phát triển mạnh mẽ, việc khai thác các bộ dữ liệu lịch sử bằng các phương pháp học máy không chỉ mang ý nghĩa học thuật mà còn giúp thể hiện khả năng ứng dụng của các công nghệ mới trong việc nhận diện rủi ro và hỗ trợ ra quyết định. Trước đây, nhiều nghiên cứu chỉ sử dụng các mô hình truyền thống như Logistic Regression hoặc các phương pháp thống kê mô tả để ước lượng xác suất sống sót. Tuy nhiên, cùng với sự tiến bộ của khoa học dữ liệu, các mô hình tiên tiến như Random Forest, Support Vector Machine (SVM) và XGBoost đã chứng minh được năng lực vượt trội trong việc xử lý dữ liệu phi tuyến và khám phá các mối quan hệ phức tạp giữa các đặc trưng.

Dẫu vậy, việc đánh giá và so sánh hiệu năng giữa các mô hình này vẫn chưa thống nhất, do sự khác biệt về tiêu chí đánh giá và quy trình tiền xử lý dữ liệu. Từ thực tế đó, nghiên cứu này được thực hiện với mục tiêu xây dựng và so sánh hiệu quả của các mô hình học máy trong dự đoán khả năng sống sót của hành khách Titanic. Nghiên cứu tập trung vào các bước tiền xử lý dữ liệu, tạo và chọn đặc trưng (feature engineering), đồng thời đánh giá mô hình bằng phương pháp K-Fold Cross Validation.


Kết quả kỳ vọng của nghiên cứu là xác định được mô hình có hiệu năng tối ưu, đồng thời làm rõ vai trò của từng đặc trưng đối với khả năng sống sót. Qua đó, nghiên cứu góp phần củng cố hiểu biết về ứng dụng học máy trong khai thác dữ liệu lịch sử và mở rộng khả năng áp dụng vào các bài toán dự đoán trong thực tiễn.

2. Tập dữ liệu

2.1 Tổng quan về tập dữ liệu

Dữ liệu này mô phỏng danh sách hành khách trên chuyến tàu RMS Titanic bị đắm vào năm 1912, với mục tiêu chính là dự đoán khả năng sống sót của từng hành khách dựa trên các thông tin cá nhân và đặc điểm hành trình. Tập dữ liệu bao gồm hai phần chính, là tập huấn luyện và tập kiểm tra. **Tập huấn luyện** chứa thông tin của 891 hành khách cùng với nhãn mục tiêu (Survived) biểu thị tình trạng sống sót (1: sống sót, 0: tử vong). **Tập kiểm tra** gồm 418 hành khách, không có nhãn Survived, được dùng để đánh giá khả năng tổng quát hóa của mô hình. Dựa trên tập dữ liệu về các thông tin của các hành khách đã có mặt trên con tàu Titanic, các hành khách còn sống và đã chết.

Tuy nhiên, sau khi xem xét và đánh giá lại các dữ liệu chúng tôi đã có một cách nhìn chi tiết hơn về mức độ phức tạp của nhiệm vụ này. Thứ nhất là về vấn đề **giá trị thiếu**, cụ thể với số lượng giá trị bị thiếu ở cột Cabin lên tới 687 dòng (gần 80%) và cột Age thiếu 177 dòng (gần 20%). Bên cạnh đó cột Age và Fare có các giá trị outlier rất lớn, những điều này đã tạo ra một trở ngại đáng kể trong việc đào tạo mô hình của chúng tôi sao cho hiệu quả, vì sự chênh lệch này sẽ làm cho mô hình thiên lệch về các đặc trưng có giá trị lớn hơn, việc này sẽ cản trở khả năng học tập của các mô hình. Thứ hai, trong quá trình kiểm tra chúng tôi cũng phát hiện ra **sự thiếu hụt về các mối tương quan** giữa một số biến của bộ dữ liệu, việc thiếu các mối tương quan này đã làm phức tạp sự nỗ lực của chúng tôi trong việc xác định các mối quan hệ và cản trở khả năng dự đoán của các mô hình.



tiêu chí đánh giá mô hình

2.2 Cấu trúc dữ liệu

Bộ dữ liệu ban đầu có 12 cột đặc trưng chính, bao gồm:

Thuộc tính	Ý nghĩa
PassengerId	Mã định danh của hành khách
Survived	Biến mục tiêu: 1 nếu sống sót, 0 nếu không
Pclass	Hạng vé (1: hạng nhất, 2: hạng nhì, 3: hạng ba)
Name	Họ tên hành khách
Sex	Giới tính
Age	Tuổi
SibSp	Số anh/chị/em hoặc vợ/chồng đi cùng
Parch	Số cha/mẹ hoặc con đi cùng
Ticket	Mã vé
Fare	Giá vé
Cabin	Số phòng (nhiều giá trị bị thiếu)
Embarked	Cảng khởi hành (C: Cherbourg, Q: Queenstown, S: Southampton)

Bảng 1: Các thuộc tính của mô hình

3. Các thí nghiệm và mô hình

3.1 Các mô hình

Trong nghiên cứu này, chúng tôi triển khai và so sánh hiệu suất của năm mô hình học máy tiêu biểu: K-Nearest Neighbors(KNN), Logistic Regression, Random Forest, Support Vector Machine(SVM) và XGBoost. Mỗi mô hình mang đặc trưng riêng trong cách học và tổng quát hóa, giúp đánh giá đa chiều về hiệu quả của các kỹ thuật xử lý đặc trưng trong bài toán dự đoán khả năng sống sót của hành khách trên tàu Titanic.

Mô hình K-Nearest Neighbors (KNN): KNN là một trong những mô hình đơn giản và dễ hiểu nhất, hoạt động dựa trên nguyên lý “hàng xóm gần nhất”. Dự đoán của KNN được xác định dựa trên nhãn của k điểm dữ liệu gần nhất trong không gian đặc trưng. Ưu điểm của KNN là *không giả định phân phối dữ liệu* và có khả năng nắm bắt quan hệ cục bộ tốt. Tuy nhiên, mô hình dễ bị ảnh hưởng bởi nhiễu, đặc biệt trong dữ liệu có nhiều biến liên tục hoặc chưa được chuẩn hóa. Trong bài toán Titanic, KNN được kỳ vọng phản ánh tốt mối quan hệ giữa các hành khách có đặc điểm tương đồng, chẳng hạn như cùng hạng ghế hoặc độ tuổi.

Mô hình Logistic Regression (LR): Logistic Regression là mô hình tuyến tính phổ biến trong các bài toán phân loại nhị phân. Phương pháp này ước lượng xác suất sống sót thông qua hàm *logistic*, giúp dễ dàng diễn giải ảnh hưởng của từng biến đầu vào. Ngoài ra, Logistic Regression còn cho phép áp dụng các kỹ thuật chuẩn hóa và regularization (L1, L2) để giảm hiện tượng quá khớp. Trong nghiên cứu này, Logistic Regression được xem là mô hình nền tảng, giúp đánh giá hiệu quả của các đặc trưng mở rộng được tạo ra trong các thí nghiệm sau.

Mô hình Random Forest (RF): Random Forest là một mô hình ensemble learning thuộc nhóm bagging, kết hợp nhiều cây quyết định huấn luyện trên các mẫu dữ liệu ngẫu nhiên. Cách tiếp cận này giúp *giảm phương sai*, hạn chế overfitting và cải thiện khả năng khái quát hóa. Random Forest đặc biệt phù hợp với dữ liệu bảng có các mối quan hệ phi tuyến và tương tác phức tạp giữa các biến, như trong tập dữ liệu Titanic. Mô hình này còn cung cấp khả năng đo lường tầm quan trọng của từng đặc trưng (feature importance), hỗ trợ phân tích chuyên sâu sau huấn luyện.

Mô hình Support Vector Machine (SVM): SVM là một mô hình mạnh mẽ trong các bài toán phân loại, hoạt động dựa trên nguyên lý tìm *siêu phẳng tối ưu (optimal hyperplane)* để tách biệt các lớp dữ liệu. Với hàm nhân *RBF (Radial Basis Function)*, SVM có khả năng học được các mối quan hệ phi tuyến giữa các đặc trưng. Trong bài toán Titanic, nơi dữ liệu không hoàn toàn tuyến tính, SVM được kỳ vọng mang lại hiệu năng ổn định và khả năng tổng quát hóa cao. Các tham số như C và γ (gamma) được tinh chỉnh bằng phương pháp xác thực chéo (cross-validation) nhằm đạt hiệu quả tối ưu.

Mô hình XGBoost (Extreme Gradient Boosting): XGBoost là mô hình boosting hiện đại, hoạt động dựa trên việc *xây dựng dãy cây quyết định liên tiếp*, trong đó mỗi cây mới học từ phần sai lệch của cây trước. Với cơ chế regularization mạnh mẽ, tốc độ huấn luyện cao và khả năng xử lý tốt dữ liệu bị thiếu, XGBoost thường đạt hiệu suất vượt trội trong nhiều bài toán dự đoán. Trong bài toán Titanic, XGBoost được xem là mô hình có tiềm năng cao nhất nhờ khả năng học sâu vào các đặc trưng phi tuyến và tương tác phức tạp giữa các biến.

3.2 Các thí nghiệm (Experiments)

Sau khi lựa chọn năm mô hình trên, chúng tôi tiến hành ba thí nghiệm để đánh giá tác động của các mức độ xử lý đặc trưng khác nhau:

Exp 1 – No Feature Engineering: chỉ xử lý dữ liệu cơ bản, không bổ sung đặc trưng mới.

Exp 2 – Feature Engineering với FamilySize: thêm đặc trưng FamilySize nhằm thể hiện mối quan hệ giữa số người thân đi cùng và khả năng sống sót.

Exp 3 – Full Feature Engineering: mở rộng thêm các đặc trưng IsAlone, Title, CabinPrefix, Embarked,... giúp mô hình khai thác tối đa thông tin tiềm ẩn trong dữ liệu.

Ba thí nghiệm này cho phép đánh giá mức độ ảnh hưởng của kỹ thuật trích xuất đặc trưng (feature engineering) lên hiệu năng của từng mô hình, từ đó rút ra kết luận về hướng tiếp cận tối ưu cho dữ liệu dạng bảng như Titanic.

4. Triển khai thí nghiệm

Cấu hình thí nghiệm

Thí nghiệm	Tên đặc trưng	Số lượng đặc trưng	Mô tả
Exp1	noFE	7	Sử dụng các đặc trưng gốc, không áp dụng kỹ thuật tạo đặc trưng.
Exp2	FamilySize	9	Bổ sung đặc trưng FamilySize (kết hợp SibSp và Parch).
Exp3	fullFE	13	Áp dụng đầy đủ kỹ thuật tạo đặc trưng, bao gồm FamilySize, Title, CabinType, v.v.

Bảng 2: chi tiết các thí nghiệm

Kết quả tổng quát theo từng thí nghiệm

Thí nghiệm	Mô hình	CV Accuracy	CV ROC AUC	Public Score
Exp1	LR	0.7912	0.8484	0.76555
Exp1	RF	0.8047	0.8545	0.7488
Exp1	XGB	0.8238	0.8602	0.71291
Exp1	KNN	0.6981	0.7297	0.62918
Exp1	SVM	0.6724	0.7380	0.66267
Exp2	LR	0.8272	0.8677	0.7823
Exp2	RF	0.8193	0.8727	0.78229
Exp2	XGB	0.8406	0.8727	0.622
Exp2	KNN	0.8193	0.8643	0.77511
Exp2	SVM	0.8216	0.8523	0.78229
Exp3	LR	0.8541	0.9099	0.73923
Exp3	RF	0.8474	0.8982	0.81578
Exp3	XGB	0.8371	0.9295	0.75358
Exp3	KNN	0.8216	0.8603	0.77511
Exp3	SVM	0.8417	0.9002	0.72577

Bảng 3: Kết quả tổng quát các mô hình theo các thí nghiệm

Dựa vào *Bảng 3* sau khi khởi chạy các thí nghiệm với 5 model đã nêu từ trước, dễ thấy rằng, mô hình có điểm Public Score cao nhất là Random Forest (Exp3) với 0.81578. Mô hình có độ chính xác (CV Accuracy) cao nhất là Logistic Regression (Exp3) với 0.8541 và mô hình có ROC AUC cao nhất là XGBoost (Exp3) với 0.9295.

Việc bổ sung đặc trưng FamilySize (Exp2) đã cải thiện rõ rệt hiệu năng so với tập đặc trưng gốc (Exp1). Tuy nhiên, khi áp dụng đầy đủ kỹ thuật tạo đặc trưng (Exp3), các mô hình học máy — đặc biệt là Random Forest và XGBoost — đạt được hiệu năng vượt trội cả về độ chính xác và khả năng phân biệt (ROC AUC). Điều này cho thấy tầm quan trọng của việc xây dựng đặc trưng phù hợp trong các bài toán phân loại.

CV metrics (Accuracy, ROC AUC) cho thấy hầu hết mô hình cải thiện rõ rệt khi chuyển từ Exp1 → Exp2 → Exp3 (tức là Feature Engineering giúp tăng hiệu năng trên khóa chéo). Tuy nhiên, nhiều mô hình có khoảng cách lớn giữa CV (đặc biệt CV ROC AUC) và Public Score — đây là dấu hiệu khả năng overfitting, không khớp phân phối giữa train/holdout/test, hoặc lỗi trong pipeline (ví dụ: tiền xử lý không nhất quán giữa train và submission).

Random Forest (Exp3) có Public Score cao nhất 0.81578 và CV metrics cũng rất tốt → đây là mô hình có khả năng khái quát hoá tốt nhất trên dữ liệu test public. XGBoost thường có CV ROC AUC rất cao (Exp3: 0.9295) nhưng Public Score thấp hơn kỳ vọng (Exp3: 0.75358) → mạnh trên tập huấn luyện / CV nhưng có dấu hiệu overfitting hoặc mismatch preprocessing / leakage. Một số trường hợp bất thường cần chú ý ngay: Exp1 XGB (CV_ACC 0.8238 / CV_AUC 0.8602)

nhưng Public 0.71291; Exp2 XGB (CV_ACC 0.8406 / AUC 0.8727) nhưng Public 0.622 (rớt rất mạnh!) — cần kiểm tra kỹ.

5. Kết luận

Mặc dù quá trình xử lý dữ liệu và xây dựng mô hình gặp phải nhiều thách thức — đặc biệt trong khâu làm sạch dữ liệu, lựa chọn đặc trưng và kiểm soát hiện tượng overfitting — nghiên cứu đã đạt được những kết quả tích cực và có giá trị thực tiễn. Qua ba nhóm thí nghiệm (Exp1 – không có đặc trưng mở rộng, Exp2 – bổ sung đặc trưng FamilySize, và Exp3 – áp dụng đầy đủ các đặc trưng được trích xuất), nhóm đã tiến hành so sánh, đánh giá hiệu năng của năm mô hình học máy truyền thống và hiện đại gồm: Logistic Regression, K-Nearest Neighbors (KNN), Random Forest, Support Vector Machine (SVM) và XGBoost.

Kết quả thực nghiệm cho thấy, việc bổ sung và thiết kế đặc trưng hợp lý đóng vai trò then chốt trong việc cải thiện hiệu suất dự đoán. Đặc trưng FamilySize giúp tăng rõ rệt độ chính xác trung bình của tất cả các mô hình trong Exp2, cho thấy tầm quan trọng của việc khai thác mối quan hệ giữa các hành khách. Khi mở rộng sang bộ đặc trưng đầy đủ (Exp3), độ chính xác trung bình (CV Accuracy) và khả năng phân biệt (ROC AUC) của hầu hết các mô hình đều tăng mạnh, phản ánh hiệu quả của chiến lược Feature Engineering trong việc mô hình hóa dữ liệu dạng bảng của Titanic.

Xét trên toàn bộ thí nghiệm, mô hình Random Forest trong Exp3 đạt hiệu suất tổng thể cao nhất, với độ chính xác trung bình qua xác thực chéo (CV Accuracy) đạt 0.8474, ROC AUC đạt 0.8982, và Public Score cao nhất là 0.81578 trên tập kiểm thử công khai. Mô hình này thể hiện khả năng tổng quát hóa tốt, cân bằng giữa độ chính xác huấn luyện và khả năng dự đoán thực tế. Trong khi đó, Logistic Regression và SVM cho thấy tính ổn định cao, phù hợp với dữ liệu có cấu trúc rõ ràng, còn XGBoost mặc dù có ROC AUC rất cao trong giai đoạn huấn luyện nhưng xuất hiện hiện tượng overfitting, dẫn đến kết quả thấp hơn mong đợi trên tập công khai.

Từ các phân tích trên, có thể khẳng định rằng Feature Engineering đóng vai trò quan trọng hơn cả việc lựa chọn mô hình trong bài toán này. Sự cải thiện về hiệu suất giữa Exp1, Exp2 và Exp3 minh chứng cho giá trị của việc hiểu rõ dữ liệu, mã hóa chính xác các đặc trưng danh mục và tạo ra những đặc trưng mang tính ngữ cảnh, chẳng hạn như FamilySize hay Title. Ngoài ra, quá trình chuẩn hóa dữ liệu, xác thực chéo và tối ưu siêu tham số đã giúp giảm thiểu sai lệch mô hình, đảm bảo tính ổn định của kết quả.

Trong tương lai, nhóm nghiên cứu dự kiến sẽ mở rộng phạm vi thực nghiệm theo hai hướng chính:

(1) Áp dụng các kỹ thuật học sâu (Deep Learning) và ensemble learning (stacking, blending) để kết hợp sức mạnh của nhiều mô hình;

(2) Tối ưu hóa pipeline tiền xử lý dữ liệu, bao gồm hiệu chỉnh tham số, xử lý dữ liệu mất cân bằng và cải thiện chiến lược xác thực chéo nhằm nâng cao hơn nữa khả năng tổng quát hóa.

Nhìn chung, nghiên cứu đã chứng minh được rằng các mô hình học máy truyền thống như Random Forest và Logistic Regression, khi được kết hợp với kỹ thuật chọn lọc và xử lý đặc trưng thích hợp, hoàn toàn có thể đạt được hiệu suất cao và ổn định trong các bài toán dự đoán thực tế như Titanic - Machine Learning from Disaster.

Tài liệu tham khảo

- [1] Ai, Y. (n.d.). *Predicting Titanic Survivors by Using Machine Learning*.
- [2] Amalia, N. &. (2022). *Comparison of Machine Learning Classification Models in Predicting the Titanic Survival Rate. International Journal of Computer Science and Artificial Intelligence*.
- [3] Breiman, L. (2001). "Random Forests." *Machine Learning*, 45(1), 5 - 32.
- [4] Chen, T. &. (2016). *XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- [5] Huy, N. Q. (n.d.). "ICIT24_Fraud_Detect_Paper": *Addressing data imbalance in insurance fraud prediction using sampling techniques and robust losses*".
- [6] Kaggle. (2024). *Titanic - Machine Learning from Disaster Dataset*.
- [7] Wenqing Liang, B. B. (2023). *Comparison of Machine Learning Classification Models in Predicting The Titanic Survival Rate*.